

Desarrollo de una Aplicación Web para la Búsqueda de Gatos Desaparecidos Usando Visión por Computadora y Modelos de Machine Learning para la Identificación de Patrones Visuales en Cali

Dillan Steven Molina Castro

Docente: José Luis Paniagua y Jesús Alfonso López Sotelo

Universidad Autónoma de Occidente

Introducción

En los últimos años, la rápida integración de la Inteligencia Artificial en la vida cotidiana ha transformado la manera en la cual nos relacionamos con el entorno, trayendo consigo consecuencias de distintos tipos. Cambiando el paradigma entendiéndola como una herramienta, la cual puede favorecer el desarrollo de proyectos desde distintos enfoques en las distintas áreas de estudio, esto en pro del avance colectivo y las variadas problemáticas sociales que hoy en día enfrentamos como humanidad.

La mascota, o más específicamente los gatos o perros domésticos, durante la historia han sido el acompañante del humano. En los últimos años, las mascotas han pasado de ser utilizadas como simples acompañantes, protectoras del hogar o ayudantes de caza a ser parte del núcleo familiar, inclusive cambiando nuestras formas de relacionarnos emocional y cognitivamente con estos, justo como lo menciona National Geographic España en su artículo "¿Una nueva domesticación? Así está cambiando el carácter de los perros con la vida moderna", escrito por el periodista Abel G. M. el 2 de noviembre de 2024, donde estudian la domesticación histórica del perro.

Según la organización especialista Lost Pet Research, en su informe "Estadísticas de mascotas perdidas", se da a conocer que, según un estudio realizado por Weiss y otros en el

año 2012, se concluyó que entre el 11 y 16 % de los perros y entre el 12 y 18 % de los gatos tienen probabilidad de desaparecer al menos una vez en un periodo de cinco años, donde solo existe del 1 al 5 % de probabilidad de encontrarlos en gatos y del 1.5 al 4.5 % en perros. Tras el cambio histórico de ver a la mascota como un simple objeto de caza o protección a verla y entenderla como un familiar más moldeando incluso nuestra forma de vivir y relacionarnos, se presenta una estadística alarmante tras la posibilidad de perder a un familiar.

Existen miles de fundaciones que se encargan de brindar un hogar de paso a las mascotas en situación de calle, muchas de estas pérdidas por falta de sistemas que organicen la información de manera adecuada. En un artículo publicado por EL TIEMPO titulado *"Animales en condición de calle, una problemática creciente que exige acción y compromiso"*, se revela que la Secretaría de Salud estima que Colombia tiene entre 2 y 3 millones de animales en situación de calle, lo cual representa cifras alarmantes que causan que estos hogares de paso sobrepasen en muchos casos su capacidad de albergue.

Este panorama se agravó recientemente con el sismo ocurrido el 10 de agosto en Colombia más específicamente en el departamento del Chocó, Cali, Pereira y sus cercanías, por mencionar algunas de las zonas afectadas, se causó la pérdida de la vida de aproximadamente 335 personas y el reporte como extraviado de más de 298 animales a través de redes sociales, según cifras reportadas por el portal web de la revista El Pulso.

Ante este panorama, nace la necesidad de centralizar la información y crear sistemas de búsqueda e identificación de mascotas automatizados.

Descripción del problema

Actualmente los métodos de organización de la información para pérdida de mascotas sufren de una gran desventaja, las publicaciones no son vistas por muchas o son aplastadas por nuevas publicaciones cada segundo, tal como pasa en grupos de mascotas perdidas en distintas aplicaciones ya sea Facebook y/o WhatsApp. Debido a variados factores, como abrir una simple puerta o que falle el sistema de localización ya sea por batería o falta de dispositivos cercanos para transmitir la información, nos lleva a aceptar un aspecto muy doloroso el no poder prevenir la desaparición de la mascota al 100% y que los actuales métodos de distribución de la información no den abasto al reporte de todas las desapariciones, dejando de ver el problema simplemente como la desaparición, sino la falta de acceso a un portal con la información centralizada.

Tras la identificación de dos grupos afectado. Grupo A, personas que han perdido a sus mascotas y que han intentado o no distintos medios para encontrarlas, el Grupo B: Personas que tengan mascotas actualmente. Se llevaron a cabo cuatro entrevistas semiestructuradas con preguntas abiertas, dos recolectadas de forma escrita vía correo electrónico y dos realizadas de manera sincrónica mediante videollamada.

El análisis cualitativo de estos testimonios reveló un patrón entre los distintos participantes: la descentralización de la información. Cada uno de manera individual y sin hablarles del problema planteado, terminaron por confirmar la hipótesis principal del proyecto.

(En la sección de Anexos se adjunta el cuestionario estructurado con las preguntas dirigidas a ambos grupos de análisis, así como el enlace directo con las evidencias documentales y grabaciones de las entrevistas realizadas).

Definición del Proyecto y Propuesta de Solución

1. Descripción General del Sistema

Como respuesta a la ineficiencia y dispersión en la búsqueda de mascotas extraviadas mediante redes sociales y canales informales, se propone el desarrollo de un aplicativo unificado enfocado en la ciudad de Santiago de Cali. La plataforma integra una arquitectura híbrida que combina un módulo de filtrado categórico por metadatos con un modelo de visión por computadora especializado en la reidentificación felina (Re-ID).

El sistema articula tres perfiles de usuario interactivos en una red de búsqueda cruzada:

- Refugios y Albergues: Entidades dedicadas al rescate animal que registran los ejemplares ingresados bajo su custodia o en alojamiento temporal.
- Usuarios Reportantes de Hallazgos: Ciudadanos que publican registros de felinos encontrados en la vía pública o en condición de extravío reciente.
- Tutores en Búsqueda: Personas que han perdido a su gato y generan reportes activos de rastreo.

La plataforma realiza búsquedas cruzadas simultáneas: los reportes de los tutores se evalúan tanto contra la base de datos de hallazgos de ciudadanos como contra los registros de los refugios.

Mecanismo de Coincidencia e Inferencia

El flujo para la identificación de coincidencias entre los registros se ejecuta en dos etapas lógicas consecutivas:

1. Filtrado Categórico y Flexible por Metadatos: Durante el registro del reporte, las variables categóricas básicas (color primario del pelaje, patrón de manchas y tamaño/edad aproximada) se capturan mediante formularios estandarizados. A nivel de base de datos se aplica un filtrado ponderado, evitando que errores de apreciación visual por parte de los usuarios excluyan arbitrariamente una coincidencia potencial.
2. Reidentificación Visual mediante Embeddings (Modelo de IA): Sobre el subconjunto filtrado, la Red Neuronal Convolutiva (CNN) procesa las fotografías para extraer sus vectores de características (embeddings). El sistema calcula la distancia espacial en el espacio vectorial y despliega un ranking de posibles coincidencias ordenado por grado de similitud.

2. Caracterización de Datos, Análisis Exploratorio (EDA) y Estrategia de Modelamiento

Origen y Volumen del Dataset de Entrenamiento

El entrenamiento y validación del modelo de Re-ID se realiza utilizando el repositorio público consolidado con identificadores únicos por individuo:

- Dataset Felino (Cat-Individuals / Re-ID Cat): Compuesto por 13.106 fotografías en formato JPEG/RGB distribuidas entre 509 individuos únicos (con un promedio aproximado de 26 imágenes por individuo) y un volumen total en disco de aproximadamente 11,25 GB. Este conjunto proporciona la base de datos necesaria para el aprendizaje de patrones de pelaje y rasgos faciales felinos.



Figura 1. Muestra representativa de imágenes del dataset Cat Re-ID, ilustrando la variabilidad de entornos, iluminación y encuadres por individuo.

- El dataset cuenta con 8 columnas de distintos tipos, las cuales son:
 - file_path: Esta columna almacena la ubicación de cada uno de los archivos. Fundamental para el acceso a distintas fotografías que presenten patrones normales a archivos corruptos.

- `dir_name`: Esta columna almacena el nombre del directorio donde se encuentra cada una de las fotos de los individuos, ya que el dataset organiza a cada uno de los individuos de manera individual por carpeta. Fundamental para realizar el análisis por individuo.
- `file_name`: Esta columna almacena el nombre de cada una de las fotos con las cuales se cuenta, el formato tiene la forma: `id_fotoN`
Ejemplo: Gato número 1, foto 0 (0001_000)
- `format`: Esta columna almacena la información correspondiente al formato de las fotos de cada uno de los individuos (por ejemplo, JPEG, JPG y PNG) previniendo errores de lectura o la inclusión de archivos corruptos durante la carga en memoria.
- `resolution`: Esta columna almacena la información correspondiente a la resolución de las fotos de cada uno de los individuos. Fundamental para evaluar la calidad de cada una de las fotos.
- `ratio`: Esta columna almacena la información correspondiente al ratio de las fotos de cada uno de los individuos. Fundamental para determinar la orientación de las fotos y para procesos de Data-Augmentation.

- **mode:** Esta columna almacena la información correspondiente al módulo de color de las fotos de cada uno de los individuos. Fundamental para verificar la consistencia con el número de canales de entrada y estandarizar o realizar la conversión a tres canales de entrada.
- **file_size_mb:** Esta columna almacena la información correspondiente al tamaño de las fotos de cada uno de los individuos. Fundamental para comparar la compresión de los distintos formatos.

En la **Tabla 1** se presenta una muestra representativa del dataset procesado con la estructura de variables final.

	file_path	dir_name	file_name	format	resolution	ratio	mode	file_size_mb
0	data/reid_cat\0001\0001_000.JPG	0001	0001_000	JPEG	7990272	1.33	RGB	0.795949
1	data/reid_cat\0001\0001_001.JPG	0001	0001_001	JPEG	7990272	1.33	RGB	0.730849
2	data/reid_cat\0001\0001_002.JPG	0001	0001_002	JPEG	7990272	1.33	RGB	0.748957
3	data/reid_cat\0001\0001_003.JPG	0001	0001_003	JPEG	7990272	1.33	RGB	0.795803
4	data/reid_cat\0001\0001_004.JPG	0001	0001_004	JPEG	7990272	1.33	RGB	0.753259

Tabla 1. Muestra representativa de la estructura de metadatos extraída para el pipeline de preprocesamiento.

Análisis Exploratorio de Datos (EDA)

Con el fin de validar la integridad, formato y representatividad de las imágenes previo al proceso de entrenamiento, se ejecutó un EDA sobre el conjunto de datos felino, obteniendo los siguientes hallazgos principales:

- **Integridad de Datos:** No se identificaron valores nulos o faltantes en ninguna de las variables del dataset, garantizando un conjunto de datos completo y listo para el procesamiento.
- **Estructura e Integridad de Formatos:** El 100% de los registros analizados corresponden a archivos en formato .jpeg bajo el espacio de color RGB de 3 canales, sin evidencias de archivos corruptos o etiquetas nulas.
- **Distribución de Clases por Individuo:** El análisis revela una media de aproximadamente 25,7 imágenes por gato, lo que garantiza muestras suficientes por identidad para alimentar las funciones de pérdida de aprendizaje métrico (Triplet Loss), las cuales requieren múltiples imágenes distintas del mismo individuo por lote (batch).
- **Consistencia Dimensional y Resoluciones:** A través del análisis estadístico descriptivo del *dataset*, se identificó una amplia variabilidad tanto en el peso de los archivos como en la resolución de las imágenes. Se detalla en la **Tabla 2**, la resolución presenta una media cercana a los 8 Mpx ($\approx 7.99 \times 10^6$ px), abarcando desde muestras con apenas 50 Kpx hasta imágenes en alta definición que alcanzan los 16 Mpx ($\sigma \approx 4.38$ Mpx).

	resolution	ratio	file_size_mb
count	13,106.00	13,106.00	13,106.00
mean	9,047,259.51	1.09	0.66
std	4,377,287.40	0.31	0.35
min	50,895.00	0.46	0.01

	resolution	ratio	file_size_mb
25%	7,990,272.00	0.75	0.45
50%	7,990,272.00	1.33	0.65
75%	12,000,000.00	1.33	0.87
max	15,925,248.00	1.78	3.00

Tabla 2. Estadísticos descriptivos globales de los metadatos de las imágenes del dataset.

- Se analizó la distribución continua del peso de los archivos (MB) y la relación de aspecto (*Aspect Ratio*). Como se aprecia en la **Figura 2**, la distribución del peso muestra una asimetría positiva con concentraciones principales entre 0.5 MB y 1.0 MB. Por su parte, la relación de aspecto evidencia una clara bimodalidad, concentrando la gran mayoría de muestras en proporciones verticales (≈ 0.75) y horizontales (≈ 1.33).




Figura 2. Distribución de frecuencias y densidad (KDE) para el tamaño de archivo en megabytes (izquierda) y la relación de aspecto ancho/alto (derecha) del conjunto de datos.

En la **Figura 3** se observa que el conjunto está dominado por composiciones horizontales (7,473 muestras) y verticales (5,512 muestras), mientras que las imágenes cuadradas representan un volumen marginal (121 muestras).




Figura 3. Distribución categórica de la orientación espacial de las imágenes.

Esta heterogeneidad espacial justifica técnicamente la implementación de un *pipeline* de preprocesamiento para la estandarización dimensional, el reescalado y la normalización de todas las muestras a una dimensión fija (224×224 px) previo a su ingreso en la red neuronal.

Finalmente, se evaluó la frecuencia de muestras asignadas a cada individuo dentro del *dataset*. En la **Figura 4** se evidencia un desbalance de clases significativo, donde el número de imágenes registradas por gato varía ampliamente entre individuos. Fundamentando el uso de un esquema de muestreo balanceado, durante la fase de entrenamiento.




Figura 4. Distribución de la frecuencia de imágenes por individuo en el dataset, evidenciando el desbalance de clases.

Transfer Learning, Fine-Tuning y Estrategia contra el Domain Gap

Para optimizar el proceso de entrenamiento y evitar el sobreajuste (overfitting) que implicaría entrenar una red neuronal desde cero, la arquitectura adopta una estrategia de Transfer Learning con Fine-Tuning:

1. **Extractor de Características:** Se utiliza una arquitectura convolucional estándar (como ResNet-50). Esta aporta el aprendizaje de patrones visuales básicos (bordes, texturas, formas e iluminación).
2. **Adaptación a Re-ID:** Se remueve la capa final de clasificación estándar (1.000 clases) y se acopla una cabeza de proyección, que reduce la salida a un vector denso de características de 512 dimensiones.
3. **Fine-Tuning con Aprendizaje Métrico:** Mediante la ejecución de algoritmos de optimización guiados por Triplet Loss, se ajustan las capas superiores de la red utilizando las 13.106 imágenes del dataset felino. La red aprende a mapear las imágenes de un mismo gato en puntos cercanos del espacio vectorial y a distanciar las de gatos diferentes.

Para contrarrestar la brecha de dominio entre las imágenes de entrenamiento y las fotografías tomadas por usuarios en el entorno real (con ruido, movimiento u oclusiones), se aplica un aumento de datos (Data Augmentation) durante el entrenamiento offline:

- Transformaciones estocásticas como variaciones de brillo, contraste y saturación.
- Desenfoque por movimiento y rotaciones aleatorias.

- Oclusión parcial y ruido gaussiano para forzar al modelo a extraer patrones de pelaje e invariantes a las condiciones de captura.

3. Evaluación del Modelo, Partición de Datos y Umbrales de Confianza

Partición de Datos Libre de Contaminación por Individuo

Para evitar el sobreajuste típico en Re-ID al mantener imágenes de una misma identidad en entrenamiento y prueba, la división del dataset se realiza estrictamente por ID de individuo:

- 70% Entrenamiento: Individuos asignados exclusivamente para el ajuste de pesos de la red.
- 15% Validación: Individuos destinados a monitorear el desempeño durante el entrenamiento.
- 15% Prueba: Individuos totalmente inéditos para el modelo, evaluando la capacidad real de generalización ante felinos jamás vistos antes en el sistema.

Métricas de Evaluación

La efectividad del sistema de recuperación se evalúa mediante:

- mAP (mean Average Precision): Precisión media promedio global de la recuperación vectorial y ordenamiento del ranking de similitud.

- Rank-1 y Rank-5: Porcentaje de casos donde el felino correcto aparece en la primera posición o dentro de las primeras cinco opciones del ranking, respectivamente.

Filtrado de Resultados y Definición del Umbral de Confianza

Para evitar la entrega de falsos positivos al usuario, se define un umbral de similitud mínimo de referencia (aproximadamente 0.65), el cual será calibrado analizando la curva de Precision-Recall sobre el conjunto de validación.

- Si la coincidencia con mayor puntaje posee un valor inferior al umbral calibrado, el sistema notificará que no se registraron hallazgos con suficiente grado de certeza.
- La publicación ingresará automáticamente al estado de "Búsqueda Activa", habilitando sugerencias secundarias basadas exclusivamente en metadatos.

4. Stack Técnico y Arquitectura Local

Para la ejecución del prototipo en entorno de desarrollo local, el stack tecnológico comprende:

- Entorno de Modelamiento: Python 3.12 con librerías PyTorch / TensorFlow para la definición, entrenamiento y extracción de vectores.
- Módulo de Inferencia y Persistencia: Entorno local en Python coordinado con almacenamiento vectorial, para el cálculo de distancia coseno entre el vector de la imagen de consulta y los vectores almacenados de los felinos registrados.

Verificación Anti-fraude, Salida de Registro y Gestión de Datos

Flujo de Confirmación Anti-fraude y Salida del Sistema

- Verificación: La coincidencia arrojada por el modelo de IA activa un protocolo de verificación en el que el tutor debe aportar evidencias complementarias de titularidad (carné de vacunación, distintivos físicos o fotografías históricas) antes de habilitar el contacto directo con el reportante o refugio.
- Cierre de Caso y Salida de Búsqueda Activa: En el momento en que se confirme la reidentificación exitosa y la mascota sea reencontrada, la publicación cambia automáticamente a estado "Encontrado" y sale inmediatamente del flujo de búsqueda activa, evitando sobrecargar las consultas del motor vectorial con casos ya resueltos.

Depuración de Registros

Al tratarse de una iniciativa sin ánimo de lucro orientada al apoyo comunitario:

- Depuración Automática: Los reportes que no registren coincidencias ni actividad tras un periodo de 180 días serán retirados del sistema activo.
- Eliminación de Archivos: Toda la información asociada a la mascota (fotografías y registros de metadatos) se eliminará de la base de datos activa para mantener optimizado el almacenamiento local. Si el tutor o refugio requiere mantener la búsqueda, podrá volver a registrar la información y publicar las imágenes en la plataforma sin ningún inconveniente.

5. Alcance, Delimitación E impacto Esperado del Proyecto

Alcance

- Diseño e implementación de la interfaz funcional local para los tres roles (Refugios, Reportantes y Tutores).
- Módulo de ingesta y filtrado flexible por metadatos.
- Análisis exploratorio de datos (EDA), entrenamiento offline mediante Transfer Learning / Fine-Tuning, integración y evaluación del modelo estático de Re-ID especializado en felinos para la extracción de embeddings empleando métricas mAP, Rank-1 y Rank-5.
- Generación de listas ordenadas por similitud visual ajustadas por umbrales de confianza.

Delimitación

- El prototipo se delimita exclusivamente a la reidentificación de la especie felina, considerando la representatividad del dataset disponible. La extensión a la especie canina queda planteada como trabajo futuro.
- El prototipo opera de manera local y no realiza reentrenamiento dinámico en tiempo real, el modelo opera como un extractor de características estáticas previamente entrenado.
- La precisión del análisis de Re-ID está supeditada a la calidad, nivel de iluminación, enfoque y variabilidad angular de las fotografías suministradas por los usuarios.

Impacto Esperado:

- Técnico: Desarrollo de un pipeline robusto de visión por computador (Re-ID) adaptado a la morfología del felino, capaz de extraer *embeddings* a condiciones no controladas de iluminación, ángulo y calidad de imagen.
- Social: Disminución drástica del tiempo de búsqueda y encuentro de felinos perdidos, superando la ineficiencia de los métodos tradicionales (carteles y publicaciones en redes sociales).
- Bienestar Animal: Reducción de la sobrepoblación de animales en condición de calle y descongestión de refugios.
- Económico: Implementación de una herramienta no invasiva y de bajo costo operativo que no depende de dispositivos físicos costosos para el propietario.

Cuadro comparativo de revisión bibliografía técnica

Referencia	Fuente	Metodología	Resultados y Hallazgos	Relevancia para el Proyecto
Xiao, W., Zhang, W., & Liu, H. (2025). Enhancing Endangered Feline Conservation in Asia via a Pose-Guided Deep Learning Framework for Individual Identification. <i>Diversity</i> , https://www.mdpi.com/1424-2818/17/12/853	MDPI (Multidisciplinary Digital Publishing Institute) Google Scholar	Utiliza dos redes neuronales las cuales se enfocan en observar al felino y sus características en el caso de la primera red y la segunda los patrones de pelaje a través de las poses, haciendo uso de redes preentrenada como ResNet-152 y ResNet-34, usa regulación L2 adaptativa, la cual penaliza los pesos cuando se tienen muy pocas fotos y entrena el modelo usando Hard Triplet Loss y Cross Entropy como función de pérdida.	Alcanza un mAP del 91.3% y Rank-1 del 98.9% en el dataset ATRW (Tigres de Amur), superando a modelos previos. Evaluado en un dataset de leopardos de las nieves (WCS) logró un mAP del 94.5%	Presenta una validación al usar regiones de pelaje y posturas para evitar el sobreentrenamiento en reidentificación individual de tigres de Amur y el Leopardo de las nieves. Esto es un gran aporte al proyecto, pudiendo llamarlo la columna vertebral que da garantía al proyecto al identificar felinos a través de procesos de reidentificación usando CNN.
Roa García, F. A. (2021). <i>Implementar un sistema de reconocimiento e identificación de rostros sobre secuencias de video mediante un modelo de Redes Neuronales Convolucionales y Transfer Learning</i> (Trabajo de grado de maestría, Universidad Nacional de Colombia). Repositorio Institucional UNAL. https://repositorio.unal.edu.co/items/97a0c7d7-aa19-4038-a976-b2e2cb78cde1	Repositorio UNAL (Universidad Nacional de Colombia) Google Scholar	Compara el uso de distintos hardware Colab y Hardware Local Jetson Nano, esto utilizando transferlearning adoptando el método dlib en una red preentrenada ResNet-34, extrayendo un vector de características por cada rostro, para clasificar atributos haciendo uso de KNN.	Obtuvo una precisión alta, en la mayoría de sus individuos, y un rendimiento superior en el desarrollo del modelo de reconocimiento facial en Colab, con GPU Tesla T4.	Presenta una metodología distinta en a través del uso del algoritmo de KNN para clasificación y presenta así mismo un análisis sobre distintos hardware para el desarrollo de estos modelos de reconocimiento de individuos.
Yi, D., Lei, Z., Liao, S., & Li, S. Z. (2014). Deep metric learning for person re-identification. In 2014 22nd International Conference on Pattern Recognition (pp. 34-39). http://www.cbsr.ia.ac.cn/users/zlei/papers/ICPR2014/Yi-ICPR-14.pdf	CBSR (Center for Biometrics and Security Research) Google Scholar	Divide cada imagen del cuerpo captado por cámaras en tres parches horizontales solapados que son procesados en paralelo por tres Redes Convolucionales Siamesas (SCNN), extrayendo un vector de características de 500 dimensiones por cada región mediante capas convolucionales y totalmente conectadas, para clasificar la similitud individual haciendo uso de una capa de similitud coseno entrenada con la función de pérdida Binomial Deviance y un costo asimétrico.	Alcanzó un Rank-1 del 28.23% y Rank-30 del 92.28% en el dataset VIPeR, con fotografías de resolución baja de 48*128 píxeles.	Aunque haya logrado métricas bajas, para su tiempo fue revolucionario. Este revela las desventajas del uso de redes propias y el beneficio del uso del Fine-Tuning.
Durand Espinoza, J. A. (2018). <i>Reidentificación de Personas Basada en Aprendizaje de</i>	Universidad Católica San Pablo (UCSP)	Modelo propio que procesa 4 regiones horizontales de la imagen con superposición de	Logró un Rank-1 de 81.20% en CUHK01, 65.50% en CUHK03 y	Respaldada directamente la arquitectura de

<i>Características de Partes del Cuerpo Mediante Redes Convolucionales en Triplet Loss</i> (Tesis de maestría, Universidad Católica San Pablo). Repositorio Institucional UCSP, https://repositorio.ucsp.edu.pe/backend/api/core/bitstreams/a0c7d804-c8fe-4494-bd8b-875018d42c3d/content	Google Scholar	32 píxeles. Utiliza módulos Inception y capas densas para generar <i>embeddings</i> de 256-D por región. Aplica <i>Triplet Loss</i> mejorado junto con la técnica de <i>Data Augmentation</i> (Random Erasing) y asignación de pesos dinámicos a cada sección del cuerpo.	34.40% en PRID2011 (con Re-ranking). Demostró viabilidad para procesamiento en tiempo real (>50 FPS)	parches por regiones del cuerpo (AL2) combinada con <i>Triplet Loss</i>. Demuestra que asignar pesos diferenciados a las regiones corporales, optimiza la precisión en problemas de reidentificación de sujetos.
Cambrón Blanco, S. (2025). <i>Ilusiones ópticas y modelos de aprendizaje profundo: Estudio del espacio de características de modelos fundacionales</i> (Trabajo de Fin de Grado, Universidad de Zaragoza). Repositorio ZAGUAN, https://zaguan.unizar.es/record/164742/files/TAZ-TFG-2025-3081.pdf?version=1	Repositorio Institucional ZAGUAN (Universidad de Zaragoza) Google Scholar	Para entender el comportamiento de distintos modelos con ilusiones ópticas, uso dos modelos, el modelo de visión DINOv2 auto supervisado de Meta y el modelo multimodal Clip de OpenAI, con el uso de una red siamesa, analizando sus embeddings y PCA en RGB.	DINOv2 organizo el espacio más latente con percepción humana y contexto global y Clip resulto ser más sensible a detalles como el color, DINOv2 obtuvo resultados superiores a CLIP con un R^2 de 0.86 en formas y 0.94 en imágenes naturales. Aun así, ningún modelo interpreto correctamente las ilusiones de tamaño y contorno difuso.	Demuestra el uso del método Fine Tuning usando modelos preentrenados de empresas muy reconocidas en el ámbito de la inteligencia artificial, para capturar características estructurales.

Anexos

Grupo A: Personas que perdieron una mascota

1. ¿Cuántas mascotas tienes actualmente y de qué raza(s) son?
2. Cuando se perdió tu mascota, ¿tú fuiste quien tomó las decisiones y buscó activamente, o alguien más se encargó (y tú viviste la situación desde otro rol, por edad, distancia, u otra razón)? Cuéntame brevemente cuál fue tu situación.
3.
 - *Si actuaste:* Cuéntame paso a paso qué hiciste en las primeras 24 horas.
 - *Si no pudiste actuar directamente:* Cuéntame qué recuerdas de esas primeras 24 horas: ¿qué viste qué hacían los demás?, ¿qué querías hacer tú y no pudiste?, ¿qué sentiste al no poder involucrarte como querías?
4. Del 1 al 10, ¿qué tan en control sentiste la situación en ese momento? (1 = totalmente impotente/sin poder hacer nada; 10 = con control total de lo que pasaba).
¿Por qué te pusiste esa nota?
5. ¿Qué herramientas, apps, grupos de Facebook, carteles, etc. se usaron para buscarla? Si tú pudiste buscar, cuéntame cuáles sirvieron y cuáles no. Si no pudiste buscar, cuéntame qué recuerdas que se usó, o qué hubieras querido que se usara y no se usó.

6. Del 1 al 10, ¿qué tan difícil recuerdas que fue conseguir información útil (avistamientos, zonas de búsqueda) en ese proceso? (1 = muy fácil; 10 = extremadamente difícil).
- *Si pudiste buscar:* ¿Qué fue lo más frustrante de esa parte?
 - *Si no pudiste buscar:* ¿Qué fue lo más frustrante de estar del otro lado, sin poder conseguir o dar esa información tú mismo/a?
7. ¿Hubo algo que te limitó a ti (o a quien buscaba) para actuar mejor o más rápido? Puede ser dinero, tiempo, edad, no saber qué hacer, distancia, salud mental, lo que sea.
8. Si pudieras rediseñar ese proceso desde cero, seas tú quien busca o quien observa/apoya ¿qué es lo primero que cambiarías o qué herramienta te hubiera encantado tener?

Grupo 2: Personas que actualmente tienen mascota (no la han perdido)

1. ¿Qué medidas de prevención tienes actualmente para evitar que tu mascota se pierda (chip, placa, collar con GPS, etc.)? Cuéntame por qué elegiste esas y no otras.
2. ¿Qué opinas de los métodos que la gente usa hoy para buscar mascotas perdidas, como publicar en Facebook o pegar carteles? ¿Sientes que realmente funcionan, o que una publicación se pierde rápido entre cientos de posts nuevos y termina sin verla casi nadie?

3. Del 1 al 10, ¿qué tan preparado/a te sientes hoy para reaccionar si tu mascota se perdiera mañana? (1 = nada preparado; 10 = totalmente preparado). ¿Qué te falta para sentirte más seguro/a?
4. Si tu mascota se perdiera hoy, ¿cuáles serían los primeros 3 pasos que harías, en orden?
5. ¿Qué te limitaría o te frenaría a la hora de buscar activamente a tu mascota (tiempo, dinero, no saber por dónde empezar, miedo, etc.)?
6. Del 1 al 10, ¿qué tan dispuesto/a estarías a pagar por un servicio o app que aumente las probabilidades de encontrar a tu mascota rápido? (1 = no pagaría nada; 10 = pagaría lo que fuera necesario). ¿Qué monto te parecería razonable?
7. Si existiera una herramienta ideal para prevenir pérdidas o encontrar mascotas más rápido, ¿cómo te imaginas que funcionaría? Descríbela como si se la explicarás a un amigo.

Drive con preguntas: <https://drive.google.com/drive/folders/18x9r7OzcQBWmmkpFvzU4k9PTgI-7A7Ud?usp=sharing>

Repositorio de GitHub con el desarrollo del documento y EDA:

https://github.com/317745/IA_PROJECT

Bibliografía

8. **National Geographic:** Abel, G. M. (2024, 2 de noviembre). *¿Una nueva domesticación? Así está cambiando el carácter de los perros con la vida moderna*. National Geographic España.
https://www.nationalgeographic.com.es/mundo-animal/nueva-domesticacion-asi-esta-cambiando-caracter-perros-vida-moderna_23560
9. **Lost Pet Research:** Lost Pet Research and Recovery. (2019, 14 de marzo). *Lost Pet Statistics*. Lost Pet Research & Recovery.
<https://lostpetresearch.com/2019/03/lost-pet-statistics/>
10. **El Tiempo (Noticia / Reportaje):** El Tiempo. (s. f.). *Animales en condición de calle: Una problemática creciente que exige acción y compromiso*. El Tiempo. <https://www.eltiempo.com/vida/mascotas/animales-en-condicion-de-calle-una-problematica-creciente-que-exige-accion-y-compromiso-3544170>
11. **Infobae (Reporte de agencia EFE):** Newsroom Infobae. (2026, 15 de septiembre). *Colombia suma cuatro muertos más por el terremoto y eleva a 335 el total de fallecidos*. Infobae.
<https://www.infobae.com/america/agencias/2026/09/15/colombia-suma-cuatro-muertos-mas-por-el-terremoto-y-eleva-a-335-el-total-de-fallecidos/>
12. **Pulzo:** Pulzo. (2026, 14 de agosto). *Animales perdidos tras emergencia en Cali: Reporte oficial de la UAEPa y balance actualizado*. Pulzo.
<https://www.pulzo.com/vivir-bien/mascotas/animales-perdidos-tras->

[emergencia-en-cali-reporte-oficial-de-la-uaepa-y-balance-actualizado-PP5275092A](#)

13. **ScienceDirect (Artículo científico):** ScienceDirect. (s. f.). *[Enlace a artículo científico en ScienceDirect]*. Elsevier.
<https://www.sciencedirect.com/science/article/pii/S240589632401694X>
14. **Virtual Pro (Artículo técnico/científico):** VirtualPro. (s. f.). *PatchMask: Una estrategia de aumento de datos con ruido gaussiano en imágenes hiperespectrales*. VirtualPro. <https://www.virtualpro.co/articulos/patchmask-una-estrategia-de-aumento-de-datos-con-ruido-gaussiano-en-imagenes-hiperespectrales-364946>
15. **Google Machine Learning Crash Course:** Google. (s. f.). *Clasificación: Exactitud, precisión, recall y métricas relacionadas*. Google Developers - Machine Learning Crash Course. <https://developers.google.com/machine-learning/crash-course/classification/accuracy-precision-recall?hl=es-419>
16. **Repositorio Universidad Nacional de Colombia (UNAL):** Universidad Nacional de Colombia. (s. f.). *[Título del recurso académico / Tesis]*. Repositorio Institucional UNAL.
<https://repositorio.unal.edu.co/items/97a0c7d7-aa19-4038-a976-b2e2cb78cde1>
17. **Repositorio Universidad Católica San Pablo (UCSP - Tesis AETCNN):**
Durand Espinoza, J. A. (2018). *Reidentificación de personas basada en aprendizaje de características de partes del cuerpo mediante redes convolucionales en Triplet Loss* (Tesis de maestría, Universidad Católica San Pablo). Repositorio Institucional UCSP.

<https://repositorio.ucsp.edu.pe/backend/api/core/bitstreams/a0c7d804-c8fe-4494-bd8b-875018d42c3d/content>

18. **MDPI (Artículo en Revista MDPI - Diversity):** MDPI. (s. f.). [*Artículo académico en Diversity / MDPI*]. MDPI. <https://www.mdpi.com/1424-2818/17/12/853>
19. **Paper Científico (ICPR 2014 - Deep Metric Learning / Triplet Loss):** Yi, D., Lei, Z., Liao, S., & Li, S. Z. (2014). *Deep Metric Learning for Person Re-identification*. En *2014 22nd International Conference on Pattern Recognition (ICPR)* (pp. 34-39). IEEE.
<http://www.cbsr.ia.ac.cn/users/zlei/papers/ICPR2014/Yi-ICPR-14.pdf>
20. **Trabajo de Fin de Grado (Universidad de Zaragoza - Modelos Fundacionales / Espacio de Características):** Cambrón Blanco, S. (2025). *Ilusiones ópticas y modelos de aprendizaje profundo: Estudio del espacio de características de modelos fundacionales* (Trabajo de Fin de Grado, Universidad de Zaragoza). Repositorio ZAGUAN, <https://zaguan.unizar.es/record/164742/files/TAZ-TFG-2025-3081.pdf?version=1>